

SOLARIS



Sobre o Nome

A palavra "Solaris" vem do latim e significa "relativo ao sol", simbolizando clareza e direção no universo complexo dos investimentos. Assim como o sol guiou explorações ao longo da história, o Solaris utiliza o índice Bovespa como referência para identificar oportunidades, ajustar alocações de forma eficiente e construir portfólios otimizados, priorizando desempenho consistente e controle de risco.

Design do robô



A Estratégia

O Solaris é uma estratégia de Deep Learning desenvolvida para otimizar os retornos de uma carteira composta exclusivamente por ativos subjacentes ao índice Bovespa, enquanto controla rigorosamente o tracking error. A abordagem combina análise de regimes de mercado, identificação de características preditivas dos ativos, previsões de curto prazo e modelagem de custos de transação. Com um modelo dinâmico e altamente estruturado, o Solaris ajusta as alocações de forma eficiente, visando superar o desempenho do índice dentro de parâmetros bem definidos de risco e consistência.

Tipo de Estratégia	Trade
Classe de Ativos	Ações
Universo	Bovespa
Benchmark	Ibovespa
Plataforma de Teste	Python
Holding Period	1 dia
Média de trades /mês	400

Mais do que seguir o índice

Uma introdução ao *Enhanced Index Tracking*

Superar o mercado é um dos maiores desafios para investidores e gestores. Custos altos, fatores emocionais e a imprevisibilidade do mercado fazem com que a maioria acabe ficando para trás. No Brasil, por exemplo, quando olhamos para os últimos 10 anos, mais de 80% dos fundos de investimento tiveram uma performance inferior ao mercado¹. Diante disso, recorrer à simplicidade do investimento passivo nos parecia ser a decisão mais sensata. Essa abordagem garante o retorno médio do mercado, com custos reduzidos e sem a necessidade de grandes análises. Entretanto, não conseguíamos evitar o questionamento: será que a melhor opção é se contentar com a média? Seria possível adotar uma estratégia com um pouco mais de ambição?

É exatamente essa questão que o *Enhanced Index Tracking* (EIT) tenta responder. Esse tipo de estratégia opera exclusivamente com as ações subjacentes ao índice, buscando otimizar a composição do portfólio de maneira a replicar sua performance com maior eficiência e potencial de retorno superior. Em vez de comprar todas as ações na mesma proporção do índice, o EIT seleciona um subconjunto de ativos e ajusta suas alocações estrategicamente, mantendo o comportamento geral do benchmark, mas aproveitando oportunidades específicas que podem surgir. É uma forma de combinar a estabilidade do investimento passivo com uma abordagem ativa controlada e disciplinada. Entretanto, o EIT tradicional enfrenta limitações significativas. Quando implementado manualmente, ele depende de análises subjetivas e decisões que podem ser influenciadas por vieses e erros de julgamento. Além disso, a complexidade de identificar ativos-alvo e ajustar posições pode gerar custos operacionais elevados e comprometer a eficiência da estratégia. Enfim, retorna-se aos mesmos problemas da gestão ativa tradicional.

É aqui que a tecnologia se destaca. Com o uso de algoritmos de *Deep Learning*, é possível analisar grandes volumes de dados históricos, identificando padrões complexos e ajustando as alocações de forma objetiva e precisa. Essa automação reduz os custos de transação, elimina vieses e melhora a eficiência da estratégia, permitindo implementar o EIT com maior controle sobre os riscos e potencial de retorno. Assim, utilizando recursos de artigos acadêmicos de finanças e *machine learning*, desenvolvemos o Solaris: um algoritmo projetado para integrar características como regimes de mercado e fatores de curto prazo do índice Bovespa suas ações de forma a executar uma estratégia de *Enhanced Index Tracking* no mercado de ações brasileiro.

1. Fonte: Pesquisa SPIVA, realizada pela S&P. "Mercado" representado pelo índice S&P Brasil LargeCap.

Transformando dados em decisões

Regra de Investimento / Arquitetura da Rede Neural

Para a construção do modelo, nos baseamos no artigo *Deep Learning for Enhanced Index Tracking* (DAI e LI, 2024), que apresenta uma arquitetura inovadora de rede neural, em que múltiplas redes independentes são conectadas como “blocos” de uma rede principal, cada um com o propósito de executar uma tarefa específica. A rede neural recebe como entrada um conjunto de atributos dos ativos e do índice de mercado, permitindo que o modelo identifique padrões e faça decisões sobre a alocação em cada ativo do portfólio. Os atributos utilizados são:

1. Probabilidades suavizadas dos regimes do índice

Consideramos que há dois regimes de mercado: *bull* e *bear*. Essa feature representa a probabilidade de o índice estar no regime *bull*. Os regimes são determinados por um Modelo Oculto de Markov com ruído gaussiano de dois estados, que ajusta parâmetros como a média e variância dos retornos para cada regime e calcula a probabilidade de transição entre os estados com base em uma cadeia oculta de Markov. A inferência dos regimes é feita calculando, para cada ponto no tempo, a probabilidade a posteriori de cada regime gerar os retornos observados. Finalmente, obtemos a probabilidade suavizada através da média das 2 últimas probabilidades de regime.

2. Probabilidades suavizadas dos regimes das ações

Calculadas com o Modelo Oculto de Markov, da mesma maneira que o índice, mas para cada ação isoladamente.


3. Métricas de curto prazo

Para cada ação, calculamos a média, volatilidade e beta em uma janela de 5 dias. Para o índice, calculamos a média e volatilidade. Essas métricas ajudam a explicar o comportamento recente dos ativos, além de mostrar a relação dos ativos com o índice.

4. Pesos dos ativos antes do rebalanceamento

Os pesos dos ativos antes do rebalanceamento foram utilizados para controlar custos de transação inerentes as mudanças de alocação nos ativos.

Cada uma das features é designada individualmente a um bloco específico, que a utiliza como input para ajustar os pesos de cada ação no portfólio a cada rebalanceamento. A seguir, apresentamos a arquitetura da rede neural, explicando a função de cada bloco e como eles estão conectados.



1. Bloco Principal

A função do bloco principal é aprender os pesos dos ativos baseados no regime do mercado. Ele parte da ideia de que as ações se comportam de maneiras diferentes quando o mercado está em alta ou baixa, portanto seria necessário mudar as alocações de acordo com o comportamento do índice. O bloco principal recebe como *input* a probabilidade suavizada do regime do índice e gera como *output* os pesos iniciais das ações, que serão ajustados pelos próximos blocos.

2. Bloco de Score

O bloco de score atua como um mecanismo de refinamento que busca identificar ativos com potencial de desempenho diferenciado, ajustando as alocações de forma a capturar essas oportunidades. Os ativos não respondem de maneira uniforme às condições gerais de mercado, sendo necessário um olhar granular sobre seus retornos riscos. Esse bloco recebe como *input* as métricas de curto prazo de cada ativo, como volatilidade e retornos projetados, e gera como *output* scores que refletem o valor relativo de cada ação para ajustes nos pesos iniciais. Esses scores são utilizados para ajustar o vetor de pesos fornecido pelo bloco principal.

3. Bloco de Controle

O bloco de controle ajusta os pesos de cada ação considerando o estado específico de cada ativo, independentemente do estado geral do mercado, refletindo a intuição de que, mesmo em condições de mercado similares, diferentes ativos podem apresentar dinâmicas próprias. Ele recebe como *input* as probabilidades de regime de cada ativo e gera como *output* um vetor de pesos que ajusta o vetor de pesos produzido pelo bloco de *score*.

4. Bloco de Memória

O propósito do bloco de memória é reduzir custos de transação ao suavizar as mudanças nos pesos entre períodos consecutivos. Ele compara os pesos ajustados do período atual com os do período anterior e calcula o equilíbrio entre manter as alocações anteriores e incorporar os ajustes propostos. Como *input*, recebe os pesos ajustados e os históricos, e como *output*, entrega pesos suavizados que garantem transições graduais, preservando a eficiência operacional e limitando custos excessivos.

O modelo gera novos pesos com uma frequência diária, sendo essa a frequência de rebalanceamento do portfólio. Todas as posições são passíveis de ajuste conforme for determinado pelo modelo.

Coleta de dados

Para alimentar o modelo, coletamos dados do período de 4 de janeiro de 2010 a 30 de dezembro de 2023. Utilizamos a plataforma Economatica (acesso através da faculdade) para obter o valor de mercado de todas as empresas que compunham o índice Bovespa em janeiro de 2010. Em seguida, filtramos as 20 ações com maior valor de mercado, cujos *tickers* são: PETR4, VALE3, ITUB4, ABEV3, BBDC4, SANB4, BBAS3, ITSA4, CSNA3, ELET3, GGBR4, B3SA3, USIM3, JBSS3, VIVT3, BRFS3, CCRO3, CMIG3, CPFE3 e EGIE3. Utilizamos os *tickers* para baixar, utilizando a biblioteca *yfinance*, a série de preços de fechamento ajustados de todos os ativos e do índice Bovespa para o período supracitado.

“There is no free lunch”

O impacto dos custos de transação

Os custos de transação, mesmo que pareçam pequenos, podem reduzir significativamente os retornos acumulados de um portfólio ao longo do tempo. Estratégias que realizam ajustes frequentes nas alocações amplificam esses impactos, pois cada negociação adiciona despesas que se acumulam. Para maximizar a eficiência do portfólio e preservar os ganhos, é essencial adotar abordagens que limitem a necessidade de transações excessivas.

Tanto para o *backtest* quanto para o treinamento do modelo, consideramos uma taxa de 0,75% para calcular os custos de transação. Chegamos a esse valor considerando uma taxa de corretagem de 0,5% (baseado nas taxas de corretoras brasileiras) e uma taxa de *slippage* de 0,20%. *Slippage* é a diferença entre o preço esperado de uma transação e o preço efetivamente executado. Ele ocorre devido a fatores como a volatilidade do mercado e a liquidez do ativo no momento da negociação. Por exemplo, ao tentar comprar ou vender uma ação em grande volume, o preço pode mudar antes que a ordem seja totalmente executada, resultando em um custo adicional. A taxa de *slippage* proposta pode ser considerada conservadora, dado que estamos negociando ações de alta liquidez. Ademais, consideramos uma taxa adicional 0,05%, de emolumentos e custódia.

Aprendendo a vencer o mercado

Treinamento do modelo

A função de perda do modelo combina três objetivos centrais: rastreamento do índice Bovespa, busca por retorno adicional e controle de risco. Sua fórmula é:

$$\begin{aligned} \text{Perda Total} = & \lambda_1 * \text{Tracking Error} - \lambda_2 * \text{Retorno Excedente} \\ & + \lambda_3 * \text{Desvio Padrão de Retornos Inferiores ao Índice} + \lambda_4 * \text{CVAR} \end{aligned}$$

O erro de rastreamento mede a aderência do portfólio ao índice, minimizando desvios nos retornos. O retorno excedente recompensa ganhos superiores ao benchmark, incentivando a geração de alfa. Já as penalidades de desvio para baixo e CVaR tratam os riscos, penalizando perdas relativas ao índice e limitando a exposição a cenários extremos. Juntos, esses componentes equilibram replicação precisa, retorno adicional e controle rigoroso de riscos.

O treinamento foi dividido em duas etapas, utilizando dados de 2010 a 2018. Na primeira etapa, o modelo ajustou o bloco principal, o bloco de score e o bloco de controle, enquanto o bloco de memória permaneceu congelado. Esses blocos foram treinados para identificar características de mercado, calcular pontuações e gerar alocações iniciais utilizando dados históricos de todos os anos anteriores a cada janela. Para 2013, foram utilizados dados de 2010 a 2013; para 2014, de 2010 a 2014, e assim por diante. A abordagem incremental garantiu que o modelo capturasse dinâmicas históricas sem acesso a dados futuros.


Na segunda etapa, o bloco de memória foi treinado com o objetivo de ajustar o modelo às transições de alocação ao longo do período completo de treinamento (2010 a 2018). Essa etapa utilizou as alocações geradas na primeira etapa para refinar a dinâmica temporal do modelo, assegurando que as mudanças fossem consistentes com as variações históricas e os padrões de mercado.

Alguns cuidados foram tomados para evitar o *look-ahead bias*, garantindo que decisões e cálculos fossem baseados apenas em informações disponíveis até o final de cada janela. O ajuste dinâmico das probabilidades de regimes de mercado considerou exclusivamente os dados históricos disponíveis. Essa segmentação temporal assegurou que o modelo replicasse condições reais enfrentadas por gestores, resultando em decisões fundamentadas e generalizáveis.


A validação foi realizada com dados de 2019 a 2023, garantindo avaliação independente do modelo em cenários nunca vistos. Essa divisão temporal permitiu testar a capacidade de generalização em múltiplos ciclos de mercado.

Da teoria ao mercado: resultados



Backtest do modelo



	Benchmark	Portfólio
Retorno Acumulado	52,68%	188,65%
CAGR	26,56%	26,89%
Volatilidade	26,56%	26,89%
Alfa	0,00	0,14
Beta	1,00	0,92



Analisando os resultados do *backtest*, podemos observar que o portfólio supera consistentemente o índice, mantendo resultados superiores e evitando as quedas outrora sofridas. Através da inferência de momentos de alta, o modelo é capaz de aproveitar cenários positivos para gerar retornos consideravelmente superiores, ultrapassando seu benchmark. Por outro lado, em momentos de baixa, o modelo apresenta resiliência, se posicionando de maneira mais conservadora e evitando perdas. Apesar da queda sofrida juntamente com o índice em 2020, ele se mostrou capaz de seguir seu objetivo: rastrear o índice enquanto apresenta retornos positivos e superiores.



Ademais, olhando para o comportamento do CVAR ao longo do tempo, vemos que o modelo foi capaz de manter seu risco em linha com o portfólio.

Em relação ao tracking error, vemos que ele se estabiliza no longo prazo, em um valor de pouco menos que 0,007. Isso indica que o modelo foi bem-sucedido em sua aderência ao índice, enquanto capturava retornos adicionais.

Desafios e oportunidades

Avaliando as limitações e próximos passos

O modelo apresentou resultados consistentes, mas algumas limitações precisam ser endereçadas para aprimorar sua flexibilidade e eficácia. A seleção fixa das 20 empresas com maior valor de mercado em janeiro de 2010 é uma dessas limitações. Ao longo do tempo, muitas dessas empresas perderam relevância ou liquidez, o que impacta negativamente o desempenho em horizontes mais longos.

A restrição temporal dos dados, que cobre apenas o período de 2010 a 2023, também reduz a capacidade do modelo de capturar padrões associados a períodos de crise severa, como a crise de 2008, dificultando sua generalização em cenários extremos. Além disso, a necessidade de uma série histórica extensa de preços impede a inclusão de *IPOs* recentes que rapidamente se tornam relevantes, mas carecem de dados suficientes para treinamento.

Uma solução para superar essas limitações é adaptar o modelo para incluir e excluir ativos de forma dinâmica. Isso possibilitaria a incorporação de empresas que realizam *IPOs* e ganham relevância rapidamente, enquanto ativos que perdem importância ou liquidez poderiam ser removidos. Essa funcionalidade aumentaria a capacidade do modelo de refletir melhor as transformações no mercado.

Outra estratégia importante é a integração de variáveis exógenas, como notícias financeiras e indicadores macroeconômicos, para capturar mudanças estruturais no mercado, como crises econômicas ou alterações regulatórias. Essa melhoria exigiria o desenvolvimento de um novo bloco capaz de processar essas informações externas e combiná-las aos dados históricos do modelo.

Apêndice

Especificações do modelo e outros resultados

Parâmetros da rede


O modelo foi construído e testado no Python, utilizando a biblioteca PyTorch.

Os blocos principal, de controle e de memória são construídos como redes neurais com uma camada oculta com 5 nós, e uma camada de saída de um nó. O bloco de score, por ter um input de dimensão 5, possui duas camadas ocultas com 5 nós. Para todas as camadas ocultas, utilizamos a função de ativação GELU. Para as camadas de saída dos blocos principal, de controle e de memória, utilizamos a função Sigmoide, e para o bloco de score, a função de identidade (linear).

Para minimizar a função de perda, utilizamos uma variação do Stochastic Gradient Descent chamada de Adam (Adaptative Movement Estimation), com *batches* de tamanho 16, com uma *learning rate* de 0.001, treinando em 15 *epochs* para os dados acumulados a cada ano e mais 20 *epochs* para o bloco de memória.

Alocação do portfólio

Abaixo estão presentes as alocações que o modelo tomou ao longo do período. Como pode ser observado, ele foi capaz de reagir rapidamente a mudanças nos regimes e nas características das ações, segurando até mesmo caixa se necessário.



Bibliografia

Beasley, J., Meade, N., Chang, T.-J. ***An evolutionary heuristic for the index tracking problem.*** European Journal of Operational Research, 2003

Dai, Z., Li, L. ***Deep learning for enhanced index tracking.*** Quantitative Finance, 2024

Stevens, E., Antiga, L., Viehmann, T. **Deep Learning with PyTorch.** Manning Publications, 2020