


METODOLOGIA E VIESES TRATADOS

O **backtest** foi rodado ao longo de: 374 pregões (10/02/2025 a 06/08/2026), 9 ETFs a preços ajustados, rebalanceamento diário, **2,0 bps por lado** sobre o giro. Todo número desta página teve de passar por uma pergunta: o backtest podia saber isso na hora da decisão? As quatro formas de inflar um backtest (**olhar o futuro, calibrar dentro da própria janela, assumir número de manual e ajustar parâmetro ao resultado**) foram fechadas por construção, antes de rodar.

- **O modelo nunca viu o futuro.** Nenhuma view usa o desfecho do evento que ela mesma precifica.
- **Nada foi assumido de cabeça.** A sensibilidade a juros que o manual arredonda para "8" foi medida: 8,31 a 8,38.
- **A régua foi calibrada fora do teste.** As médias de referência vêm de 206 pregões anteriores ao início da janela medida.
- **Os parâmetros não foram ajustados ao resultado.** Teto de risco, confiança nas views e aversão a risco saem de decisão registrada.

CURVA ACUMULADA E DRAWDOWN




+33,2% contra +30,1% do SPY, ao mesmo risco (vol. 17,6% contra 17,9%). Mas a vantagem não veio das quedas: nos dois tombos a carteira caiu junto, e em abril/2025 caiu **mais fundo que o benchmark** (−19,6% contra −18,8%). O ganho vem da subida, não da defesa.

DE ONDE VEM O RESULTADO



O retorno de cada pregão se separa em três pedaços: a carteira de equilíbrio (o que se teria sem view nenhuma), o desvio que as views impõem sobre ela e o custo de manter esse desvio. Em 374 pregões as views produziram **+5,2 pp** e o custo devolveu **−3,0 pp**. O que chega ao investidor é o que sobra. E a vantagem **não depende de dias de sorte** sem os três pregões de maior impacto ela teria retorno maior, não menor (+4,5 em vez de +2,3 pp).

SENSIBILIDADES: AQUI SE JUSTIFICA O NÚMERO



Um resultado bom pode ser só um parâmetro bem escolhido, mas esse não é o caso. Giramos os quatro botões da estratégia: quanto risco tomar, quanta confiança dar às views, quanto o preço precisa andar para negociar e a correção das probabilidades, e medimos cada posição. **Em nenhuma a vantagem sobre o SPY vira negativa** (+0,5 a +15,8 pp).

TABELA DE MÉTRICAS

MÉTRICA	KAIRÓS	SPY
Retorno líquido	+33,2%	+30,1%
Vol. anualizada	17,6%	17,9%
Sharpe	1,18	1,08
Máx. drawdown	−19,6%	−18,8%
Alpha anual.	+2,57%	—
Beta vs SPY	0,95	1,00
Σ w média	1,91	1,00
Giro diário	0,40	—

Beta 0,95: a carteira anda junto com o mercado. Não é SPY alavancado — nem neutra: as views ficam líquidas compradas (ΣP de +0,96 a +2,00)

O QUE O NÚMERO NÃO DIZ

Ganha sozinha, perde somada. A camada tática faz +42,6 pp isolada e −2,94 pp na entrega. Sob teto de risco fixo, somar não acrescenta: divide o mesmo orçamento. E o Δ não é monótono no teto (−2,9 / −6,8 / −8,9 / +3,8).

Quase metade do giro volta atrás 42% do que a carteira compra num dia é desfeito nos dois pregões seguintes. Ainda assim a vantagem só desapareceria com um custo de 22,9 bps por lado — 11× os 2 bps que pagamos.

Uma janela, um regime. 374 pregões de alta do S&P, sem correção para as ~200 comparações da busca tática.

AUTOAVALIAÇÃO · NOSSA CONDUTA

Como julgamos a estratégia: Uma ideia entra por acertar a probabilidade, nunca por render mais; teto e confiança foram escolhidos uma vez só, em reunião; a hipótese foi escrita antes de medir.

13 ideias de sinal medidas, 1 entrou: Momentum e velocidade de ajuste viraram passeio aleatório quando medidos — o dado contrariou a tese.

2 views entregues acertando a direção em 49% dos dias: Nossa régua de entrada é ter um mecanismo que explique o efeito, não um histórico bonito. A tese se sustenta pelo que foi reprovado.

AUTOAVALIAÇÃO · ONDE ERRAMOS

Lemos uma medida errada e quase decidimos por ela: Um número parecia crescer e chamamos isso de tendência — era artefato do jeito de medir. Quem pegou: a segunda medida, feita antes de qualquer decisão, que mostrou passeio aleatório.

Nosso primeiro filtro reprovava quase tudo: A régua de estabilidade acusava 13 dos 14 casos; a correta acusa 3. Quem pegou: a releitura do critério antes de olhar o resultado — aceitá-lo teria dado a conclusão oposta da certa.

Texto cravado em gerador envelhece calado. A legenda do backtest afirmou “camada desligada” por dois commits depois de ela ser ligada — os números já a incluíam. Encontramos o erro depois em uma conferência de código .

AUTOAVALIAÇÃO · SIMULAÇÃO DE FUNDO

Perfis de cliente simulados por IA sobre a série diária: 18 meses, drawdown de −19,6%, Σ|w| médio de 1,91 e 0,40 de giro por pregão.

Conservador — não adere. Drawdown pior que o do índice, 1,9× de alavancagem, nenhuma proteção na queda.

Institucional — adere ao alpha, não ao produto. Beta 0,95 é exposição que ele já compra barato; pagaria pelos +2,6% a.a. de alpha.

Orientado a evento — adere. É o único para quem +3,0 pp ao mesmo risco do índice é o produto.

A objeção não foi ao retorno, foi ao empacotamento: isto é um overlay de alpha, e a taxa teria de sair do excesso.

A REGRA QUE ORGANIZOU O TRABALHO COM IA

Três frentes em paralelo, cada uma dona dos seus módulos e do seu branch, com as regras versionadas no próprio repositório. CLAUDE.md compartilhado e sistema de registro de decisões e trabalho por sessão. A regra central é uma só: **a IA nunca fecha decisão metodológica**. Fonte, universo, forma funcional e valor de parâmetro saem de decisão humana registrada; até ela existir, o agente escreve TODO(DECISAO-N) e toca o resto da tarefa.

- **Um dono por módulo.** Código de outro dono não se edita: o defeito vira observação no LOG dele.
- **Second-brain por branch.** Qualquer pesquisa, decisão ou dúvida ficou registrada em forma de markdown em um sistema organizado pela própria. Conhecimento que foi se construindo nunca foi perdido.
- **Ritual de sessão obrigatório.** Toda sessão fecha com entrada no LOG e um bloco "Uso de IA". Esta página sai dele.
- **CLAUDE.md para o Projeto.** Arquivo lido ao começo de cada sessão, com as regras de conduta, guia de como fechar a sessão e separação de funções por membro

DADOS GERAIS - O PROCESSO MEDIDO, NÃO ESTIMADO

SESSÕES DE IA

91

TOKENS POR SESSÃO

232k

média · 19,7M no total

DECISÕES REGISTRADAS

81

escaladas para decisão humana

TAXA DE RECORREÇÃO

37%


das sessões pediram 2ª rodada (87 medidas)

LINHA DO TEMPO DO PROJETO




Barras: contexto por dia, empilhado por frente; linha: decisões acumuladas. **Oito dias de agosto concentram o grosso do contexto** e a subida de 13 para 81 decisões. Hachurado: as 33 sessões cujo token foi convertido de “% da janela”.

TIPO DE SESSÃO - POR SESSÃO E POR TOKEN



Os 91 blocos do LOG classificados à mão, por regra fechada antes da contagem. Análise e medição leva **54% das sessões e 71% dos tokens**; código, 15% e 4%. O caro não foi escrever código — foi medir.

ERROS DA IA × MECANISMO QUE PEGOU



145 erros contados um a um nos três LOGs. Código quebrado é a maior categoria (72) e a mais barata: 40 morrem na execução. Na outra ponta, **texto impreciso (13) e escopo errado (10) não têm um único erro pego por teste** — a conferência humana pegou os 23 ainda na sessão.

A SEPARAÇÃO DO TRABALHO

- **A IA sozinha.** Código, varredura, medição repetida e prosa gerada a partir dos números: 38 scripts, 37 arquivos de teste e 40 análises só neste branch.
- **Só o humano.** Fonte, universo, forma funcional, parâmetro e o que entra na entrega — e o veredito de cada régua, escrito antes de medir.
- **Nenhum dos dois sozinho.** O critério que julga um ingrediente é humano e declarado antes; a varredura que o aplica é da IA. Trocar a ordem produziu overfit com cara de método.

ONDE A IA AGREGOU

- Varredura exaustiva ficou barata.** 13 candidatas táticas medidas antes de uma entrar, cada ingrediente do Ω testado em várias grades, horizontes e janelas — ~200 comparações só na busca tática. À mão, nada disso teria sido testado.
- Prosa gerada do número.** As páginas saem de gerador alimentado por artefato medido; a legenda muda quando o número muda.
- Revisão cruzada entre agentes.** A classificação dos 91 blocos saiu de 4 agentes com briefing único, e a conferência da própria saída pegou 3 dos 6 erros da sessão.

ONDE A IA FALHOU, E O QUE CONTEVE

- Premissa herdada, pega pelo humano.** A IA afirmou que o mapeamento cenário→ativo estava congelado; o congelado era a camada tática. Duas rodadas de correção do dono — e o registro errado já tinha entrado em duas entradas do LOG.
- Defeito latente que só um assert novo revelou.** O auto-teste do gerador desta página misturava LOG sintético com os LOGs reais — invisível desde que a função foi escrita.

PRÓXIMOS PASSOS

- Termos fora da diagonal no Ω .** É a limitação com endereço mais claro: a correlação entre views já está medida.
- Banda de não-negociação.** Contra os 42% de giro desfeito em dois pregões — o breakeven de 22,9 bps por lado diz que há espaço para não negociar.
- Ampliar o universo pelo critério certo.** Não por classe de ativo, e sim por haver notícia a que o preço responda.
- Validar em regime de queda.** O que a página 4 admite é o que falta testar: a vantagem veio da subida.

FECHAMENTO

Kairós não tenta prever o mercado, troca a opinião do gestor pelo preço de quem tem dinheiro em risco no desfecho. É o que torna a view auditável: Q e Ω deixam de ser declarados e passam a ser medidos, e o resultado passa a depender de acertar a probabilidade, não de escolher bem o parâmetro. Os +3,0 pp sobre o SPY ao mesmo risco saem daí. O que sustenta a tese não é a curva; é o que foi reprovado antes dela: 13 ideias medidas, uma entrou.