

NEXUS

"Nexus" nasce do latim nectere: ligar, entrelaçar. É o ponto onde caminhos distintos se encontram. Assim como no mercado, tecemos conexões entre ativos e revelamos padrões ocultos, transformando relações complexas em decisões claras e executáveis.



LÓGICA & ESTRATÉGIA

O projeto propõe uma forma inovadora de compreender o sistema financeiro: como uma rede viva de conexões entre empresas, onde risco e informação se propagam de maneira dinâmica. Combinando Graph Attention Networks (GAT), filtragem topológica via TMFG e métricas de distance correlation, o robô Nexus aprende a identificar padrões estruturais e alocar capital de forma adaptativa, maximizando o Sharpe. Além disso, incorpora uma camada de gestão dinâmica de caixa, que ajusta a exposição conforme as condições de mercado, equilibrando desempenho e controle de risco. A estratégia integra inteligência artificial, teoria de redes e finanças quantitativas em um modelo coeso e interpretável, voltado à eficiência e estabilidade estrutural.

CLASSE DE
ATIVOS

AÇÕES

UNIVERSO
INVESTIMENTO

B3

FREQUÊNCIA
DE ESTRATÉGIA

TRIMESTRAL

BENCHMARK

**IBOVESPA
&
EQUAL-WEIGHTED**

NEXUS

Factsheet Page

Nexus: conexão entre o mercado, risco e tempo para formar portfólios otimizados

NEXUS


O mercado é complexo demais para ser tratado como correlação estática

Identidade Visual:
Neith, deusa egípcia da criação e sabedoria: tece conexões entre ativos e informações, formando uma rede de conhecimento financeiro.



Cada ativo é um nó em uma teia em constante mudança, e entender o todo exige mais do que somar partes: é preciso ouvir as conexões

Rebalanceamento Trimestral



A Rede Invisível do Mercado

O mercado financeiro pode ser visto como um organismo social, um sistema interligado em que ações e reações de agentes formam uma teia dinâmica de dependências. Assim como em uma sociedade, onde indivíduos influenciam-se por laços de convivência, hierarquia ou informação, os ativos também mantêm conexões que moldam o comportamento coletivo. Cada empresa ocupa uma posição nessa rede, algumas exercendo influência central, irradiando risco ou confiança; outras, mais periféricas, sustentando o equilíbrio do sistema. Compreender o mercado, portanto, é desvendar as estruturas invisíveis pelas quais circulam capital, risco e informação.

Grande parte dos modelos quantitativos tradicionais, baseados em Markowitz (1952), ainda tratam os ativos como independentes, conectados apenas por correlações lineares e estáticas. Essa simplificação ignora a natureza mutável das relações entre empresas, sensíveis a ciclos econômicos, choques setoriais e eventos macroeconômicos. No Brasil, onde há alta concentração setorial e volatilidade cambial, essas conexões tornam-se especialmente instáveis. Como resultado, carteiras baseadas em correlações fixas tendem a superestimar diversificação e subestimar o contágio.

Inspirados por essa visão, adaptamos o modelo de Korangi, Mues e Bravo (2024), que combina distance correlation, filtragem topológica via **TMFG** e **Graph Attention Networks (GATs)**. Essa estrutura permite capturar dependências não lineares entre ativos e gerar alocações que maximizam diretamente o **Sharpe**, tratando o mercado como uma rede viva de relações financeiras.

Sendo assim, entendemos que explorar a topologia dinâmica de correlações, em conjunto com aprendizado de atenção, permite construir portfólios mais otimizados e com melhor relação risco-retorno do que modelos lineares tradicionais.

Coleta de dados:

A coleta de dados foi conduzida na **Economatica**, reunindo séries históricas de preços ajustados das ações da **B3**, do **Ibovespa**, da **curva do CDI** e dos **volumes diários negociados**, usados para estimar liquidez. O período analisado, de **01/01/1998** a **09/09/2025**, serviu como base para o treinamento do modelo e construção das visualizações.

As séries diárias foram ajustadas para feriados da B3 e complementadas com o **CDI diário** do Banco Central, usado como taxa livre de risco no cálculo do Sharpe ratio. A partir dos preços, calcularam-se **retornos diários** e aplicou-se **winsorização nos quantis de 1% e 99%**, reduzindo o impacto de outliers e garantindo maior robustez estatística para a modelagem.

Processo de investimento

Nossa estratégia apoia-se em dois pilares: **tendência e interdependência**. Assumimos que ações com bom desempenho recente tendem a manter o momentum, mas empresas de um mesmo setor ou fortemente conectadas compartilham riscos semelhantes. Buscamos, portanto, **maximizar o Sharpe**, equilibrando persistência de retorno e **diversificação estrutural**, evitando exposições redundantes na rede de mercado.

O processo inicia-se com o **cálculo dos retornos diários**, submetidos à winsorização para remover outliers. Em seguida, calcula-se a **volatilidade móvel de 30 dias** para cada ativo, considerando um histórico de dois anos. A partir dessas séries, constrói-se uma **matriz de dependência via distance correlation** (fórmula abaixo), métrica capaz de capturar tanto relações lineares quanto não lineares entre retornos. Diferente da correlação de Pearson, a distance correlation é nula apenas quando as variáveis são estatisticamente independentes, permitindo detectar co-movimentos sutis.




Figura 1 - Rede setorial + Matriz de correlação

O resultado é uma matriz densa D (representada setorialmente acima), na qual cada elemento $D_{ij} \in [0,1]$ expressa o grau de interdependência entre dois ativos. Essa matriz gera um grafo totalmente interconectado. Para mitigar ruídos e informações redundantes como input da rede neural, aplicamos o **Triangulated Maximally Filtered Graph (TMFG)**: método matemático que reduz drasticamente a complexidade de um grafo preservando sua estrutura de correlações. Iniciando-se com os quatro vértices mais conectados, os demais são adicionados iterativamente, priorizando combinações de maior correlação. No nosso caso, isso reduz as arestas de cerca de **2500 para 144**, mantendo a estrutura informativa essencial.




Figura 2 - Snapshot TMFG 2024_06

Esse grafo (Figura 2), juntamente com os retornos diários de cada ação nos últimos 21 pregões são os inputs da rede neural (GAT) a cada rebalanceamento.

GAT – Graph Attention Network:




Figura 1 - Estrutura interna da GAT

A rede neural **Graph Attention Network (GAT)**, implementada em **PyTorch**, transforma a saída do TMFG em pesos de portfólio. Os ativos são representados como nós contendo suas informações de retorno, enquanto as arestas refletem seus graus de interdependência.

As camadas de atenção permitem que cada ativo combine suas informações com as de seus vizinhos mais relevantes, ponderando essas conexões por coeficientes aprendidos que medem a influência de cada relação. O uso de múltiplas cabeças de atenção faz com que o modelo observe o mercado sob diferentes perspectivas simultâneas, aprendendo de forma adaptativa quais conexões são mais relevantes e ajustando-se continuamente à estrutura dinâmica dos ativos. Os embeddings (vetores de informação) resultantes passam por camadas densas, normalização em lote com ReLU, dropout e uma camada final que gera os scores individuais, enquanto as técnicas de regularização e normalização garantem estabilidade, evitam sobreajuste e asseguram que as alocações reflitam padrões estruturais e não ruídos temporários.

Na camada **Allocation Projection**, esses scores serão convertidos em pesos do portfólio, com restrições realistas: número máximo de ativos investidos (13) e limite máximo de exposição por posição (20%).

O modelo é treinado com uma função de perda que maximiza o Sharpe, penalizando também transação e turnover. Os custos de transação são incluídos na perda, levando o modelo a operar apenas quando o ganho líquido compensa o custo.

$$\mathcal{L} = -\log\left(\frac{\mathbb{E}[R_p]}{\sqrt{\text{Var}(R_p)}}\right),$$

*Função a ser minimizada → logaritmo suaviza a escala, tornando o treinamento mais estável e robusto.

A otimização é feita pelo método Adam, reaproveitando parâmetros (warm start) entre janelas consecutivas. Dessa forma, a GAT aprende como a informação se propaga na rede e traduz esse conhecimento em alocações dinâmicas e consistentes.

Em síntese, a rede atua como um sistema adaptativo, capaz de aprender, a partir da própria topologia financeira, como distribuir capital de modo inteligente, ajustando-se continuamente às interdependências entre empresas.

Camada Final - Controle de Risco:

Durante o aprendizado da rede, observou-se que o modelo frequentemente priorizava retornos mais altos à custa de maior volatilidade, buscando maximizar o Sharpe. Embora isso eleva o desempenho estatístico, uma volatilidade inconsistente e drawdowns acentuados tornam a estratégia menos realista e inadequada sob a ótica de um produto financeiro aplicável.

Como alternativa a métricas tradicionais de risco, como o Value at Risk, foi implementada uma camada adicional de controle de caixa, remunerada pelo CDI. Nessa estrutura, o drawdown do portfólio é monitorado em uma janela móvel de 21 pregões, ajustando dinamicamente a exposição entre 10% e 90%. Essa abordagem suaviza a volatilidade e preserva a relação risco-retorno.

Diferentemente de inserir o caixa dentro da rede treinável, seu percentual é definida após o cálculo dos pesos. Essa separação evita que o modelo aprenda padrões oportunistas e garante que o controle de risco seja aplicado de forma independente, sem distorcer a topologia da rede.

Backtest:

O backtest foi concebido como um experimento controlado, avaliando a robustez temporal e operacional da estratégia em ambiente realista. O modelo foi treinado entre 2000 e 2015 e testado sob um regime **walk-forward** (iniciado em 2016), com retreino anual. Isso garante separação clara entre aprendizado e execução, reduzindo o risco de overfitting e permitindo adaptação gradual aos regimes de mercado.


Para mitigar look-ahead bias, todas as informações utilizadas na construção do grafo TMFG, no cálculo das features e na definição das alocações foram limitadas ao universo de dados disponíveis até D-1. Nenhum dado futuro é incorporado, nem mesmo para normalizações ou cálculos de liquidez. O universo elegível foi composto pelas 50 ações mais líquidas, conforme média de volume dos últimos 21 pregões, evitando survivorship bias e garantindo negociabilidade real.

Premissas operacionais:

- Lookback de 2 anos para o TMFG;
- Janela de 1 mês para a série de retornos (input do GAT);
- Rebalanceamento trimestral;
- Slippage de 5 bps;
- Custo de 75,5 bps sobre o turnover (Corretagem + Bid-ask spread).

Esse desenho, aliado ao re-treino periódico, à penalização explícita de concentração e giro na função de perda, busca capturar não apenas desempenho histórico, mas também capacidade adaptativa e estabilidade estrutural, fundamentais para validade futura do modelo.

Análise de Resultados e Conclusão:




Métricas de Performance

Nome	Retorno Total	CAGR	Volatilidade	Sharpe Ratio	Max Drawdown	Beta	Alpha
Estratégia	358.98%	17.91%	18.01%	1.00	-20.90%	0.50	12.43%
Portfólio EW (Benchmark)	159.53%	10.86%	25.52%	0.53	-50.98%	1.07	-0.44%
Ibovespa	171.19%	11.59%	23.38%	0.59	-46.82%	nan	nan

O backtest mostra um desempenho expressivo da estratégia. Além do Ibovespa, foi utilizado o modelo equal-weighted no mesmo universo (50 ações mais líquidas do último mês) como referência para medir a qualidade das decisões.

Em todas as métricas, como retorno total, volatilidade e drawdown, a estratégia superou os benchmarks, apresentando alpha significativo e beta reduzido, evidenciando diversificação e resiliência estrutural. Os Sharpes ajustados pelo CDI foram de 0,53 para a estratégia, 0,10 para o equal-weighted e 0,14 para o Ibovespa.

Esses resultados confirmam que o modelo atingiu seu propósito de unir aprendizado de máquina e topologia de mercado para otimizar alocações, identificando padrões de interdependência que antecipam retornos ajustados ao risco. A função de perda baseada no Sharpe promoveu alocações eficientes, enquanto o controle de caixa dinâmico reduziu volatilidade e drawdowns sem sacrificar retorno.



É importante ressaltar que esses dados estão desconsiderando impostos. Para estimar o real rendimento com IR, consideramos o regime de **fundo de ações sem “come-cotas”**, com **alíquota de 15% sobre lucro líquido** e **compensação automática de meses negativos**. O retorno ajustado final foi de **305,18% (15,87% a.a.)**, ainda superando consideravelmente os benchmarks.

Alguns pontos de melhoria, no entanto, são bem relevantes. Entre eles, destacamos os dois principais:

Em primeiro lugar, o turnover da estratégia mostrou-se elevado: O turnover médio foi de **78,8%** no portfólio 100% em ações — valor parcialmente mitigado pelo caixa. Esse comportamento reflete a **agressividade da GAT**. Embora os custos de transação tenham sido aplicados sobre o turnover total, não é possível medir com precisão o impacto real apenas com os parâmetros atuais. Isso pode ser aprimorado com **penalizações mais fortes de turnover na loss**, **ajustes de hiperparâmetros** ou **alocação gradual de posições**, aumentando o realismo operacional e permitindo avaliar melhor o efeito do giro na performance líquida.

Em segundo lugar, o uso de preços ajustados foi adotado por conveniência, já que incorporam proventos e desdobramentos de forma automática. Entretanto, reconhecemos que essa escolha pode introduzir look-ahead bias, uma vez que a rede neural irá aprender com dados que já incluem dividendos futuros. Em uma versão aprimorada, essa limitação seria ajustada a partir da utilização de preços não ajustados, com ajustes restritos a cada janela de análise.

Em síntese, o robô **Nexus** demonstra que combinar **inteligência artificial e estrutura topológica** transforma a complexidade do mercado em decisões de investimento mais eficientes. A integração entre **GAT, TMFG e controle de caixa** garantiu equilíbrio entre aprendizado e prudência, permitindo capturar oportunidades estruturais com estabilidade. Apesar de pontos de aprimoramento, o desempenho histórico e a coerência conceitual reforçam o potencial da abordagem como uma solução inovadora para a gestão quantitativa no Brasil, revelando que o mercado se comporta como uma **rede viva de correlações**, onde compreender as conexões é tão essencial quanto analisar os retornos individuais.

Apêndice:

CAIXA (% do portfólio)

Métrica	Valor
Média:	26.99%
Mediana:	10.00%
Mínimo:	10.00%
Máximo:	90.00%
Desvio Padrão:	29.42%

PAINEL DE ANÁLISE DO PORTFÓLIO - SNAPSHOT 2022-09-27

13


0.1463

65.9%

Posições Ativas

HHI (Índice de Concentração)

Percentual em Caixa



PAINEL DE ANÁLISE DO PORTFÓLIO - SNAPSHOT 2019-12-26

13


0.1333

35.3%

Posições Ativas

HHI (Índice de Concentração)

Percentual em Caixa



Uso da IA generativo:

OBS: Os textos e análises dessa seção foram 100% gerados por IA:


Métricas de Uso e Engajamento com IA Generativa:

Durante o projeto foram utilizados **452 prompts**, com média de **15,1 por conversa** e **1.042 caracteres por interação**, refletindo alta densidade cognitiva. O **Índice de Engajamento Técnico (IET)** atingiu **81%**, indicando predominância de diálogos quantitativos e fundamentados, enquanto **40% das interações** foram correções ampliadas,

mostrando um processo contínuo de refinamento. Esses resultados demonstram um uso maduro e orientado a desempenho da IA generativa, integrada de forma estratégica para potencializar o raciocínio analítico, aumentar a eficiência e consolidar uma cultura de experimentação guiada por dados. Reconhece-se, contudo, que a IA apresentou **limitações pontuais**, como respostas imprecisas em códigos ou excesso de generalizações, corrigidas por iteração e validação empírica, o que reforçou o papel da supervisão humana no processo criativo e técnico.

Perfil e Capacidade Ideal de Investimento e Perfil do Investidor, segundo a IA: O investidor ideal para o fundo possui horizonte de médio a longo prazo (3 a 7 anos) e busca performance consistente acima do mercado, equilibrando retorno e controle de risco. Apresenta tolerância moderada à volatilidade, compreendendo que oscilações fazem parte da estratégia desde que o drawdown seja controlado. Seu objetivo financeiro é superar o CDI e o Ibovespa, mantendo Sharpe acima de 0,5 e resiliência em períodos de crise. Costuma investir entre R\$ 600 mil e R\$ 2 milhões, destinando cerca de 10% a 25% do portfólio a estratégias quantitativas para diversificação e captura de alfa sem comprometer a liquidez global.

Capacidade Operacional Ideal do Fundo, segundo a IA: A estratégia apresenta capacidade operacional ótima entre R\$ 150 e R\$ 200 milhões, faixa em que o fundo mantém eficiência máxima sem perda de liquidez ou aumento de custos de execução. Esse nível de patrimônio permite sustentar equipe, auditoria e estrutura institucional, preservando a agilidade e o controle de risco que distinguem o modelo quantitativo. Acima de R\$ 300 milhões, o impacto de mercado torna-se relevante, exigindo ajustes de liquidez e execução algorítmica.



Bibliografia:

Korangi, K., Mues, C., & Bravo, C. (2024). *Large-scale time-varying portfolio optimisation using graph attention networks*. Preprint. University of Southampton; The University of Western Ontario. Retrieved from <https://arxiv.org/abs/2407.15532>

Stevens, E., Antiga, L., Viehmann, T. Deep Learning with PyTorch. Manning Publications, 2020